

# 大数据习题

---

第2章 大数据处理架构Hadoop 单元测验

第3章 分布式文件系统HDFS 单元测验

第4章 分布式数据库HBase单元测验

第5章 NoSQL

第6章 云数据库

第7章 MapReduce

第8章 Hadoop再探讨

第9章 数据仓库Hive

第10章 Spark

第11章 流计算

第12章 Flink

第13章 图计算

## 1、简述HDFS的优缺点

优点：1) 高可靠性：采用荣誉数据存储方式，即使一个副本发生故障，其他副本也能保证正常对外提供服务

2) 高效性：作为并行分布计算平台，Hadoop采用分布式存储和分布式处理两大核心技术，能够高效的处理PB级数据

3) 高可扩充性

4) 高容错性

5) 可构建在廉价的机器上，成本低

6) 运行在linux平台上

7) 支持多种汇编语言

缺点：1) 无法高效的对大量的小文件进行存储，效率非常低

2) 一个文件只能一个线程写，只支持数据的追加，不适合并发写入

3) 不适合快速数据的存储

## 2、简述HDFS的体系结构

采用了主从（Master/Slave）结构模型，一个HDFS集群是由一个NameNode和若干个DataNode组成，其中NameNode作为主服务器，管理文件系统的命名空间和客户端对文件的访问操作。DataNode管理存储的数据。

HDFS允许用户以文件的形式存储数据，文件被分为若干个数据块，而且这若干个数据块存放在一组DataNode上，NameNode是整个HDFS的核心，它通过维护一些数据结构来记录每一个文件被分割成了多少个块，这些块可以从那些DataNode中获得，以及各个DataNode的状态等重要信息。NameNode执行文件文件系统的命名空间操作，如打开，关闭，重命名，文件或目录等，也负责数据块到具体DataNode的映射。DataNode负责处理文件系统客户端的文件读写操作，并在NameNode的统一调度下进行数据块的创建，删除和复制操作。

### 3、请论述HDFS中SecondaryNameNode的作用和工作原理

作用:

- 1) 完成 EditLog 与 FsImage 的合并操作,减少 Editlog 大小,缩短名称节点重启时间
- 2) 作为名称节点的“检查点”,保存名称节点中的元数据信息

工作原理:

- 1)SecondaryNameNode 会定期和 NameNode 通信,请求其停止使用 EditLog 文件,暂时将新的写操作写到一个新的文件 edit.new 上来
- 2)SecondaryNameNode 从 NameNode 上获取到 FsImage 和 EditLog 文件
- 3)SecondaryNameNode 将下载下来的 FsImage 载入到内存,然后一条一条地执行 EditLog 文件中的各项更新操作,使得内存中的 FsImage 保持最新;这个过程就是 EditLog 和 FsImage 文件合并
- 4)SecondaryNameNode 执行完(3)操作之后,将新的 FsImage 文件发送到 NameNode 节点上
- 5)NameNode 将从 SecondaryNameNode 接收到的新的 FsImage 替换旧的 FsImage 文件,同时将 edit.new 替换 EditLog 文件,通过这个过程 EditLog 就变小了

### 4、请论述HDFS写数据原理

- 1) 客户端向 NameNode 发起 RPC 请求，来获取请求文件 Block 数据块所在的位置
- 2) NameNode 检测元数据文件，会视情况返回 Block 块信息或者全部 Block 块信息，对于每个 Block 块NameNode 都会返回含有该 Block 副本的 DataNode 地址。
- 3) 客户端会选取排序靠前的 DataNode 来依次读取 Block 块（如果客户端本身就是 DataNode，那么将从本地直接获取数据），每一个 Block 都会进行 CheckSum（完整性验证），若文件不完整，则客户端会继续向 NameNode 获取下一批的 Block 列表，直到验证读取出来文件是完整的，则 Block 读取完毕
- 4) 客户端会把最终读取出来所有的 Block 块合并成一个完整的最终文件

### 5、详细阐述大数据，云计算和物联网三者之间的区别和联系

区别:

大数据侧重于对数据的存储，处理和分析

云计算旨在整合和优化各种IT资源，并通过网络以服务的方式廉价的提供给用户

物联网是实现物物相连，应用创新的物联网的核心

联系:

整体上三者相辅相成

大数据根植于云计算，大数据的很多计划都来自于云计算，大数据为云计算提供了“用武之地”，有了大数据才能发挥云计算的价值，物联网获取大量数据是大数据的重要数据来源，并且物联网需要借助云计算和大数据计算，实现大数据的存储，分析和处理

## 6、试述Hadoop的项目结构以及每个部分的具体功能

Hadoop的核心为HDFS和MapReduce，以及Hive等其他功能组件

Hadoop = HDFS+Yarn+MapReduce+Hbase+Hive+Pig+...

HDFS：是GFS的开源实现，具有处理超大数据，流式处理并且可以运行在廉价的商用服务器上，降低成本

HBase：一种提供高性能，高可靠性等优点的列式数据库，采用HDFS作为底层数据存储，具有良好的横向扩展能力，可以增加商用服务器

MapReduce：利用map函数和reduce函数，进行分布式计算

Hive：基于Hadoop的数据仓库工具

Pig：一种数据流语言和运行环境，来查询大型半结构化数据集

Zookeeper：分布式协调服务

Flume：高可用的，高可靠的，分布式的海量日志采集

## 7、举例说明大数据的关键技术

### 一、大数据接入

1) 大数据接入：已有数据接入、实时数据接入、文件数据接入、消息记录数据接入

2) 大数据接入技术：Kafka、ActiveMQ、ZeroMQ、Flume

### 二、大数据存储

1) 大数据存储：结构化数据存储、半结构化数据存储、非结构化数据存储

2) 大数据存储技术：Hdfs、Hbase、Hive、S3、Kudu、MongoDB、Neo4J

### 三、数据分析挖掘

1、大数据分析与挖掘：离线分析、准实时分析、图片识别、语音识别、机器学习

2、大数据分析与挖掘技术：MapReduce、Hive、Pig、Spark、Flink

## 16、分别列出四种NoSQL数据库的类型及其特点

四大类:键值数据库，列族数据库，文档数据库，图数据库

①键值数据库，特点：会使用一个哈希表，这个表中有一个特定的Key和一个指针指向特定的Value。Key可以用来定位value;value可以用来存储任意类型的数据，包括整形、字符型、数组、对象。在大量写操作的情况下，键值数据库可以比关系数据库取得更好的性能。

②列族数据库，特点：一般采用列族数据模型，数据库由多行构成，每行数据包括多个列族，不同行可以具有不同数量的列族，属于同一列族的数据会被存放在一起。

③文档数据库，特点：通过键来定位一个文档，因此可以看成键值数据库的一个延伸品，而且前者比后者具有更高的查询效率。

④图数据库，特点：使用图作为数据模型来存储数据，完全不同于键值，列族和文档数据模型，可以高效地存

储不同顶点之间的关系，图数据库专门用于处理具有高度相互关联关系的数据，可以高效地处理实体之间的关系。

### 17、试述CAP理论的具体含义

针对分布式数据库而言的，它是指在一个分布式系统中，一致性（Consistency, C）、可用性（Availability, A）、分区容错性（Partition Tolerance, P）三者不可兼得，最多只能同时满足其中2个

CA:强调一致性和可用性，放弃分区容忍性；实例：传统的关系数据库都采用了这种设计原则。

CP:强调一致性和分区容忍性，放弃可用性，实例：Neo4J, BigTable和HBase等NoSQL数据库。

AP:强调可用性和分区容忍性，放弃一致性，实例：Dynamo, Riak, CouchDB, Cassandra

### 18、HBase的分区是如何定位的

每个Hbase的分区Region都有一个RegionID来标识它的唯一性，一个Region标识符就可以表示成“表名+开始主键+RegionID”；有了Region标识符，就可以唯一标识每个Region。为了定位每个Region所在的位置可以建立一个映射表：“.META.表”，当.META.表条目很多时，.META.表也会分裂成多个Region，为了定位由建立了-Root表，-Root表是不可分割的，永远只存在一个，它的名字是在程序中被写死的，Master服务器永远知道它的位置。客户端访问用户数据之前，需要首先访问Zookeeper获取-Root表的位置信息，然后访问-ROOT-表，获得.META.表，找的所需的Region具体位于哪个Region服务器，最后才会到该Region服务器读取数据。

### 19、阐述HBase的数据分区机制

HBase 表中的所有行都是按照行键的字典序排列的。因为一张表中包含的行的数量非常多，有时候会高达几亿行，所以需要分布存储到多台服务器上。因此，当一张表的行太多的时候，HBase 就会根据行键的值对表中的行进行分区，每个行区间构成一个“分区（Region）”，包含了位于某个值域区间内的所有数据。每张表一开始只有一个 Region，但是随着数据的插入，HBase 会根据一定的规则将表进行水平拆分，形成两个 Region。当表中的行越来越多时，就会产生越来越多的 Region，而这些 Region 无法存储到一台机器上时，则可将其分布存储到多台机器上。

### 20、请以实例说明HBase数据模型

可以通过一张存储学生信息的Hbase表，学号作为行键来唯一标识每个学生，表中设计了列族Info用来保存学生相关信息，列族Info中包含3个列-name、major和email，分别用来保存学生的姓名、专业和电子邮件地址，时间戳分别为ts1=1174184619081和ts2=1174184620720，时间戳较大的数据版本是最新的数据。

### 21、试分析MapReduce为何采用Combiner可以减少数据传输量？是否所有的MapReduce程序都可以采用？

因为Combiner合并函数可以将具有相同Key的<key, value>的value加起来，例如有两个键值对< "xmu" 1 >和< "xmu" 1 >，经过合并就变成了< "xmu" 2 >；不是所有的MapReduce程序都可以采用Combiner，因为当磁盘中只有一两个溢写文件时，执行合并操作就会“得不偿失”，因为执行合并操作本身也需要代价。并不是所有都可采用。

### 22、分别描述Map端和Reduce端的shuffle过程

Map端shuffle

- 1、每个map读取原数据的一部分(inputSplit),执行Mapper操作。
- 2、从Mapper端输出的键值对数据进入到环形缓冲区(100M)

- 3、环形缓冲区容量达到80%产生溢写，写入到磁盘缓冲区。
- 4、在磁盘缓冲区中分区(partitioner)， 排序(sort)， 合并(combiner)

Reduce端shuffle

- 1、由reducetask向maptask拉取数据，进行分组排序(归并算法)
- 2、把数据组合成(key,序列)发送到Reducer类中执行
- 3、在Reducer类中处理数据，把结果写到文件中

## 第一章

1、第三次信息化浪潮的标志是：

- A.个人电脑的普及
- B.互联网的普及
- C.云计算、大数据、物联网技术的普及2.00/2.00
- D.虚拟现实技术的普及

正确答案：C你选对了

2、就数据的量级而言，1PB数据是多少TB？

- A.2048
- B.10242.00/2.00
- C.512
- D.1000

正确答案：B你选对了

3、以下关于云计算、大数据和物联网之间的关系，论述错误的是：

- A.云计算侧重于数据分析2.00/2.00
- B.物联网可以借助于云计算实现海量数据的存储
- C.物联网可以借助于大数据实现海量数据的分析
- D.云计算、大数据和物联网三者紧密相关，相辅相成

正确答案：A你选对了

4、以下哪个不是大数据时代新兴的技术：

- A.MySQL2.00/2.00
- B.Spark
- C.Hadoop
- D.HBase

正确答案：A你选对了

5、每种大数据产品都有特定的应用场景，以下哪个产品是用于批处理的：

- A.MapReduce2.00/2.00

- B.Dremel
- C.Pregel
- D.Storm

正确答案：A你选对了

6、每种大数据产品都有特定的应用场景，以下哪个产品是用于流计算的：

- A.GraphX
- B.Impala
- C.S42.00/2.00
- D.Hive

正确答案：C你选对了

7、每种大数据产品都有特定的应用场景，以下哪个产品是用于图计算的：

- A.Flume
- B.Cassandra
- C.Storm
- D.Pregel2.00/2.00

正确答案：D你选对了

8、每种大数据产品都有特定的应用场景，以下哪个产品是用于查询分析计算的：

- A.S4
- B.MapReduce
- C.HDFS
- D.Dremel2.00/2.00

正确答案：D你选对了

9、数据产生方式大致经历了三个阶段，包括：

- A.运营式系统阶段1.00/3.00
- B.感知式系统阶段1.00/3.00
- C.用户原创内容阶段1.00/3.00
- D.移动互联网数据阶段

正确答案：A、B、C你选对了

10、大数据发展的三个阶段是：

- A.低谷期
- B.萌芽期1.00/3.00
- C.大规模应用期1.00/3.00

- D.成熟期1.00/3.00

正确答案：B、C、D你选对了

11、大数据的特性包括：

- A.数据类型繁多0.75/3.00
- B.价值密度低0.75/3.00
- C.处理速度快0.75/3.00
- D.数据量大0.75/3.00

正确答案：A、B、C、D你选对了

12、图领奖获得者、著名数据库专家Jim Gray博士认为，人类自古以来在科学研究上先后经历了哪几种范式：

- A.计算科学0.75/3.00
- B.数据密集型科学0.75/3.00
- C.理论科学0.75/3.00
- D.实验科学0.75/3.00

正确答案：A、B、C、D你选对了

13、大数据带来思维方式的三个转变是：

- A.相关而非因果1.00/3.00
- B.效率而非精确1.00/3.00
- C.精确而非全面
- D.全样而非抽样1.00/3.00

正确答案：A、B、D你选对了

14、大数据主要有哪几种计算模式：

- A.图计算0.75/3.00
- B.流计算0.75/3.00
- C.查询分析计算0.75/3.00
- D.批处理计算0.75/3.00


正确答案：A、B、C、D你选对了

15、云计算的典型服务模式包括三种：

- A.PaaS1.00/3.00
- B.IaaS1.00/3.00
- C.MaaS
- D.SaaS1.00/3.00

正确答案：A、B、D你选对了

### 从Hadoop1.0到Hadoop2.0的变化



## 第2章 大数据处理架构Hadoop 单元测验

启动hadoop所有进程的命令是:

- A.start-hdfs.sh
- B.start-all.sh 2.00/2.00
- C.start-hadoop.sh
- D.start-dfs.sh

正确答案: B 你选对

以下对Hadoop的说法错误的是:

- A.Hadoop的核心是HDFS和MapReduce
- B.Hadoop MapReduce是针对谷歌MapReduce的开源实现, 通常用于大规模数据集的并行计算
- C.Hadoop是基于Java语言开发的, 只支持Java语言编程 2.00/2.00
- D.Hadoop2.0增加了NameNode HA和Wire-compatibility两个重大特性

正确答案: C 你选对了

以下哪个不是Hadoop的特性:

- A.支持多种编程语言
- B.高可靠性
- C.成本高 2.00/2.00
- D.高容错性

正确答案: C 你选对了

以下名词解释不正确的是:

- A.HBase: 提供高可靠性、高性能、分布式的行式数据库, 是谷歌BigTable的开源实现 2.00/2.00
- B.HDFS: 分布式文件系统, 是Hadoop项目的两大核心之一, 是谷歌GFS的开源实现



- C.Zookeeper：针对谷歌Chubby的一个开源实现，是高效可靠的协同工作系统
- D.Hive：一个基于Hadoop的数据仓库工具，用于对Hadoop文件中的数据集进行数据整理、特殊查询和分析存储

正确答案：A你选对了

多选(3分)

以下哪些组件是Hadoop的生态系统的组件：

- A.Oracle
- B.MapReduce1.00/3.00
- C.HDFS1.00/3.00
- D.HBase1.00/3.00

正确答案：B、C、D你选对了

多选(3分)

以下哪个命令可以用来操作HDFS文件：

- A.hdfs fs
- B.hdfs dfs1.00/3.00
- C.hadoop fs1.00/3.00
- D.hadoop dfs1.00/3.00

正确答案：B、C、D你选对了

关于三种Shell命令方式的区别：

1. hadoop fs
2. hadoop dfs
3. hdfs dfs

hadoop fs适用于任何不同的文件系统，比如本地文件系统和HDFS文件系统

hadoop dfs只能适用于HDFS文件系统

hdfs dfs跟hadoop dfs的命令作用一样，也只能适用于HDFS文件系统

## 第3章 分布式文件系统HDFS 单元测验

HDFS的命名空间不包含：

- A.块
- B.文件
- C.字节2.00/2.00
- D.目录

正确答案：C你选对了

对HDFS通信协议的理解错误的是：

- A.客户端与数据节点的交互是通过RPC（Remote Procedure Call）来实现的

- B.客户端通过一个可配置的端口向名称节点主动发起TCP连接，并使用客户端协议与名称节点进行交互
- C.名称节点和数据节点之间则使用数据节点协议进行交互
- D.HDFS通信协议都是构建在IoT协议基础之上的2.00/2.00

正确答案：D你选对了

采用多副本冗余存储的优势不包含：

- A.加快数据传输速度
- B.节约存储空间2.00/2.00
- C.保证数据可靠性
- D.容易检查数据错误

正确答案：B你选对了

假设已经配置好环境变量，启动Hadoop和关闭Hadoop的命令分别是：

- A.start-hdfs.sh, stop-hdfs.sh
- B.start-dfs.sh, stop-hdfs.sh
- C.start-hdfs.sh, stop-dfs.sh
- D.start-dfs.sh, stop-dfs.sh2.00/2.00

正确答案：D你选对了

分布式文件系统HDFS采用了主从结构模型，由计算机集群中的多个节点构成的，这些节点分为两类，一类存储元数据叫\_\_，另一类存储具体数据叫\_\_：

- A.从节点，主节点
- B.名称节点，主节点
- C.数据节点，名称节点
- D.名称节点，数据节点2.00/2.00

正确答案：D你选对了

下面关于分布式文件系统HDFS的描述正确的是：

- A.分布式文件系统HDFS是Google Bigtable的一种开源实现
- B.分布式文件系统HDFS比较适合存储大量零碎的小文件
- C.分布式文件系统HDFS是谷歌分布式文件系统GFS（Google File System）的一种开源实现2.00/2.00
- D.分布式文件系统HDFS是一种关系型数据库

正确答案：C你选对了

多选(3分)

以下对名称节点理解正确的是：

- A.名称节点的数据保存在内存中1.00/3.00
- B.名称节点用来负责具体用户数据的存储
- C.名称节点通常用来保存元数据1.00/3.00
- D.名称节点作为中心服务器，负责管理文件系统的命名空间及客户端对文件的访问1.00/3.00

正确答案：A、C、D你选对了

多选(3分)

以下对数据节点理解正确的是：

- A.数据节点的数据保存在磁盘中1.00/3.00
- B.数据节点用来存储具体的文件内容1.00/3.00
- C.数据节点在名称节点的统一调度下进行数据块的创建、删除和复制等操作1.00/3.00
- D.数据节点通常只有一个

正确答案：A、B、C你选对了

多选(3分)

HDFS只设置唯一一个名称节点带来的局限性包括：

- A.隔离问题
- B.性能的瓶颈0.75/3.00
- C.命名空间的限制0.75/3.00
- D.集群的可用性

正确答案：A、B、C、D你错选为B、C

多选(3分)

以下HDFS相关的shell命令不正确的是：

- A.hadoop fs -ls <path>：显示<path>指定的文件的详细信息
- B.hadoop fs -copyFromLocal <path1> <path2>：将路径<path2>指定的文件或文件夹复制到路径<path1>指定的文件夹中1.50/3.00
- C.hadoop dfs mkdir <path>：创建<path>指定的文件夹1.50/3.00
- D.hdfs dfs -rm <path>：删除路径<path>指定的文件

正确答案：B、C你选对了

## 第三章

### 1.试述分布式文件系统设计的需求。

| 设计需求        | 含义                            | HDFS的实现情况                         |
|-------------|-------------------------------|-----------------------------------|
| 透明性         | 具备访问透明性、位置透明性、性能、和伸缩透明性       | 只能提供一定程度的访问透明性，完全支持位置透明性、性能和伸缩透明性 |
| 并发控制        | 客户端对于文件的读写不应该影响其他客户端对同一个文件的读写 | 机制非常简单，任何时候都只允许有一个程序写入某个文件        |
| 文件复制        | 一个文件可以拥有不同位置的多个副本             | HDFS采用了多副本机制                      |
| 硬件和操作系统的异构性 | 可以在不同的操作系统和计算机上实现同样的客户端和服务端程序 | 采用Java语言开发，具有很好的跨平台能力             |
| 可伸缩性        | 支持节点的动态加入或退出                  | 建立在大规模廉价机器上的分布式文件系统集群，具有很好的伸缩性    |
| 容错          | 保证文件服务在客户端或者服务端出现问题的时候能正常使用   | 具有多副本机制和故障自动检测、恢复机制               |
| 安全          | 保证系统的安全性                      | 安全性较弱                             |

### 3.试述HDFS中的块和普通文件系统中的块的区别。

答：在传统的文件系统中，为了提高磁盘读写效率，一般以数据块为单位，而不是以字节为单位。

HDFS中的块，默认一个块大小为64MB，而HDFS中的文件会被拆分成多个块，每个块作为独立的单元进行存储。HDFS在块的大小的设计上明显要大于普通文件系统。

#### 试述HDFS的冗余数据保存策略？

- 1).第一个副本：放置在上传文件的数据节点；如果是集群外提交，则随机挑选一台磁盘不太满、CPU不太忙的节点
- 2).第二个副本：放置在与第一个副本不同的机架的节点上
- 3).第三个副本：与第一个副本相同机架的其他节点上
- 4).更多副本：随机节点

#### HDFS的局限性？

- 1).不适合低延迟数据访问 HDFS是面向大规模数据批量处理的，采用流式数据读取，具有很高的数据吞吐率，因此意味着较高的延迟。
- 2).无法高效存储大量小文件 HDFS每个块、文件和目录都占有固定的字节，如果有大量小文件，每个小文件对应一个块，将消耗很多时间找到一个文件块的位置，所需的内存也大大增加。
- 3).不支持多用户写入及任意修改文件 HDFS只允许一个文件有一个写入者，而且只允许对文件执行追加操作，不能执行随机写操作。

### HDFS体系结构的局限性（单一名称节点的局限性）？

- 1).命名空间的限制 名称节点是保存在内存中的，它能够容纳的对象个数会受到内存空间大小的限制。
- 2).性能的瓶颈 整个系统的吞吐量取决于单个名称节点的吞吐量。
- 3).隔离问题 由于集群只有一个名称节点和一个命名空间，无法对不同的应用程序进行隔离。
- 4).集群的可用性 当名称节点出故障，会导致整个集群不可用。

### 介绍HDFS错误与恢复机制的三种情形

- 1).名称节点出错 名称节点把元数据信息同步存储到其他文件系统；当名称节点宕机，利用第二名称节点进行系统恢复，但仍会丢失部分数据；结合前面两者，将远程的文件系统的元数据信息放到第二名称节点进行恢复，并作为名称节点使用。
- 2).数据节点出错 每个数据节点会定期向名称节点发送“心跳信息”，当数据节点发生故障，名称节点无法收到它们的“心跳信息”，这些数据节点就会标记为“宕机”；若一些数据块的副本数量小于冗余因子，就会启动数据冗余复制，生成新的副本。
- 3).数据出错 客户端收到数据后会进行md5和sha1校验，若错误客户端会请求到另一个数据节点读取文件块。

## 第4章 分布式数据库HBase单元测验

### 1、HBase是一种（D）数据库

- A.行式数据库
- B.文档数据库
- C.关系数据库
- D.列式数据库

### 2、下列对HBase数据模型的描述错误的是（B）

- A. HBase列族支持动态扩展，可以很轻松地添加一个列族或列
- B. HBase中执行更新操作时，会删除数据旧的版本，并生成一个新的版本
- C. 每个HBase表都由若干行组成，每个行由行键（row key）来标识
- D. HBase是一个稀疏、多维度、排序的映射表，这张表的索引是行键、列族、列限定符和时间戳

### 3、下列说法正确的是（D）

- A. 如果通过HBase Shell插入表数据，可以插入一行数据或一个单元格数据。
- B. HBase的实现包括的主要功能组件是库函数，一个Master主服务器和一个Region服务器。
- C.如果不启动Hadoop，则HBase完全无法使用。
- D. Zookeeper是一个集群管理工具，常用于分布式计算，提供配置维护、域名服务、分布式同步等。

### 4、对于HBase数据库而言，每个Region的建议最佳大小是（D）

- A.500MB-1000MB
- B.2GB-4GB
- C.100MB-200MB
- D.1GB-2GB

### 5、HBase三层结构的顺序是（A）

- A. Zookeeper文件，-ROOT-表，.META.表

- B. Zookeeper文件, .META.表, -ROOT-表
- C. -ROOT-表, Zookeeper文件, .META.表
- D. .META.表, Zookeeper文件, -ROOT-表

6、客户端是通过 (C) 级寻址来定位Region

- A. 一
- B. 四
- C. 三
- D. 二

7、关于HBase Shell命令解释错误的是 (A)

- A. list: 显示表的所有数据。
- B. create: 创建表。
- C. put: 向表、行、列指定的单元格添加数据。
- D. get: 通过表名、行、列、时间戳、时间范围和版本号来获得相应单元格的值。

8、下列对HBase的理解正确的是 (BD)

- A. HBase是一个行式分布式数据库, 是Hadoop生态系统中的一个组件。
- B. HBase是针对谷歌BigTable的开源实现。
- C. HBase是一种关系型数据库, 现成功应用于互联网服务领域。
- D. HBase多用于存储非结构化和半结构化的松散数据。

9、HBase和传统关系型数据库的区别在于哪些方面 (ABCD)

- A. 数据维护
- B. 存储模式
- C. 数据模型
- D. 数据索引

10、访问HBase表中的行, 有哪些方式 (ABC)

- A. 通过一个行键的区间来访问
- B. 全表扫描
- C. 通过单个行键访问
- D. 通过某列的值区间

**1. 试述在 Hadoop 体系架构中 HBase 与其他组成部分的相互关系。**

HBase 利用 Hadoop MapReduce 来处理 HBase 中的海量数据, 实现高性能计算; 利用 Zookeeper 作为协同服务, 实现稳定服务和失败恢复; 使用 HDFS 作为高可靠的底层存储, 利用廉价集群提供海量数据存储能力; Sqoop 为 HBase 的底层数据导入功能, Pig 和 Hive 为 HBase 提供了高层语言支持, HBase 是 BigTable 的开源实现。

**2. 请阐述 HBase 和 BigTable 的底层技术的对应关系**

- ① 文件存储系统: BigTable基于GFS, HBase基于HDFS;
- ② 海量数据处理: BigTable基于MapReduce, HBase基于Hadoop MapReduce;

③ 协同服务管理：BigTable基于Chubby，HBase基于Zookeeper；

## 8. 阐述 HBase 的数据分区机制。

HBase 采用分区存储，根据行键的值对表中的行进行分区，每个行区间构成一个分区，叫做Region。

一个大的表会被分拆许多个 Region，这些 Region 会被分发到不同的服务器上实现分布式存储。

每个Region都有一个RegionID来标识其唯一性。为了定位每个Region所在的位置，就可以构建一张映射表，\*\*映射表的每行包含两项内容：Region标识符，及Region服务器标识。\*\*从而知道某个Region被保存在哪个Region服务器中，这个映射表被叫做".META.表"。

## 9. HBase 中的分区是如何定位的。

通过构建的映射表的每个条目包含两项内容，一个是 Regionde 标识符，另一个是 Region 服务器标识，这个条目就标识 Region 和 Region 服务器之间的对应关系，从而就可以知道某个 Region 被保存在哪个 Region 服务器中。

## 11. 阐述 HBase 的三层结构下，客户端是如何访问到数据的。

首先访问 Zookeeper，获取 - ROOT 表的位置信息，然后访问 - Root - 表，获得 .META. 表的信息，接着访问 .META. 表，找到所需的 Region 具体位于哪个 Region 服务器，最后才会到该 Region 服务器读取数据。

## 16. 在 HBase 中，每个 Region 服务器维护一个 HLog，而不是为每个 Region 都单独维护一个 HLog。请说明这种做法的优缺点。

优点：多个 Region 对象的更新操作所发生的日志修改，只需要不断把日志记录追加到单个日志文件中，不需要同时打开、写入到多个日志文件中，可以减少磁盘寻址次数。

缺点：如果一个 Region 服务器发生故障，为了恢复其上次的 Region 对象，需要将 Region 服务器上的对象，需要将 Region 服务器上的 HLog 按照其所属的 Region 对象进行拆分，然后分发到其他 Region 服务器上执行恢复操作。

## 17. 当一台 Region 服务器意外终止时，Master 如何发现这种意外终止情况？为了恢复这台发生意外的 Region 服务器上的 Region,Master 应该做出哪些处理 (包括如何使用 HLog 进行恢复)?

① Zookeeper 会实时监测每个 Region 服务器的状态，当某个 Region 服务器发生故障时，Zookeeper 会通知 Master。

② Master 首先会处理该故障 Region 服务器上面遗留的 HLog 文件，这个遗留的 HLog 文件中包含了来自多个 Region 对象的日志记录。

③ 系统会根据每条日志记录所属的 Region 对象对 HLog 数据进行拆分，分别放到相应 Region 对象的目录下，然后，再将失效的 Region 重新分配到可用的 Region 服务器中，并把与该 Region 对象相关的 HLog 日志记录也发送给相应的 Region 服务器。

④ Region 服务器领取到分配给自己的 Region 对象以及与之相关的 HLog 日志记录以后，会重新做一遍日志记录中的各种操作，把日志记录中的数据写入到 MemStore 缓存中，然后，刷新到磁盘的 StoreFile 文件中，完成数据恢复；

## 18. 行式存储和列式存储的区别是什么？

- ① 行式存储使用NSM存储模型，一个元组(或行)会被连续的存储在磁盘页中。\*\*(存)数据是一行行存的，当第一行写入磁盘页后，再继续写入第二行。(读取)\*\*从磁盘中读取数据时，需要从磁盘中顺序扫描每个元组的完整内容，然后从每个元组中筛选出查询所需要的属性；
- ② 列式存储使用DSM存储模型，DSM会对关系进行垂直分解，并为每个属性分配一个子关系。因此，一个具有n个属性的关系会被分解成n个子关系，每个子关系单独存储，每个子关系只有当其相应的属性被请求时才会被访问。故列式存储以关系数据库的属性为单位进行存储，关系中多个元组的同一属性值会被存储再一起，而一个元组中不同属性值则通常会被分别存放于不同的磁盘页中；
- ③ (两者区别) 行式存储适合小批量的数据处理，但是适合于复杂的表连接的操作。列式存储适合大量的数据处理和查询。

### 19. HBase是列式存储数据库吗？

HBase严格意义上来说并不是列式存储的数据库，因为HBase是以列族为单位进行分解(列族中可以包含多个列)，而不是每个列都单独存储，但是HBase借鉴和利用了磁盘上的这种列存储格式，故而可以被称为列式存储数据库。

## 第5章 NoSQL

下列关于NoSQL数据库和关系型数据库的比较，不正确的是 (A)

- A. NoSQL数据库很容易实现数据完整性，关系型数据库很难实现数据完整性
- B. NoSQL数据库的可扩展性比传统的关系型数据库更好
- C. NoSQL数据库缺乏统一的查询语言，而关系型数据库有标准化查询语言
- D. NoSQL数据库具有弱一致性，关系型数据库具有强一致性

以下对各类数据库的理解错误的是 (D)

- A. 键值数据库的键是一个字符串对象，值可以是任意类型的数据，比如整型和字符型等
- B. 文档数据库的数据是松散的，XML和JSON文档等都可以作为数据存储在文档数据库中
- C. 图数据库灵活性高，支持复杂的图算法，可用于构建复杂的关系图谱
- D. HBase数据库是列族数据库，可扩展性强，支持事务一致性

下列数据库属于文档数据库的是 (A)

- A. MongoDB
- B. MySQL
- C. HBase
- D. Redis

NoSQL数据库的三大理论基石不包括 (B)

- A. 最终一致性
- B. ACID
- C. BASE
- D. CAP

关于NoSQL数据库和关系数据库，下列说法正确的是 (ACD)



- A. 关系数据库有关系代数理论作为基础，NoSQL数据库没有统一的理论基础
- B. NoSQL数据库和关系数据库各有优缺点，但随着NoSQL的发展，终将取代关系数据库
- C. 大多数NoSQL数据库很难实现数据完整性
- D. NoSQL数据库可以支持超大规模数据存储，具有强大的横向扩展能力

NoSQL数据库的类型包括（ABCD）

- A. 列族数据库
- B. 键值数据库
- C. 图数据库
- D. 文档数据库

CAP是指（ACD）

- A. 分区容忍性
- B. 持久性
- C. 一致性
- D. 可用性

NoSQL数据库的BASE特性是指（BCD）

- A. 持续性
- B. 基本可用
- C. 软状态
- D. 最终一致性

目前，NoSQL的含义是“Not only SQL”，而不是“No SQL”。（A）

- A. 对
- B. 错

一个数据库事务具有ACID是指：原子性，一致性，持久性，隔离性。（B）

- A. 错
- B. 对

## 6.试述键值数据库、列族数据库、文档数据库和图数据库的适用场合和优缺点。

| 数据库   | 适用场合           | 优点                                                                                  | 缺点                 |
|-------|----------------|-------------------------------------------------------------------------------------|--------------------|
| 键值数据库 | 通过键而是通过值来查的业务  | 扩展性好，灵活性好，大量写操作时性能高                                                                 | 无法存储结构化信息，条件查询效率较低 |
| 列族数据库 | 不需要ACID事务支持的情形 | 查找速度快，可扩展性强，容易进行分布式扩展，复杂性低                                                          | 功能较少，大都不支持强事务一致性   |
| 文档数据库 | 只在相同的文档上加事务    | 性能好（高并发），灵活性高，复杂性低，数据结构灵活<br>提供嵌入式文档功能，将经常查询的数据存储在同一个文档中<br>既可以根据键来构建索引，也可以根据内容构建索引 | 缺乏统一的查询语法          |
| 图形数据库 | 具有高度相互关联关系的数据  | 灵活性高，支持复杂的图形算法，可用于构建复杂的关系图谱                                                         | 复杂性高，只能支持一定的数据规模   |

## 13.试述不一致性窗口的含义。

所有后续的访问都可以读取到操作OP写入的最新值。从OP操作完成到后续访问可以最终读取到OP写入的最新值，这之间的时间间隔称为“不一致性窗口”。

## 15.什么是NewSQL数据库？

NewSQL是对各种新的可扩展、高性能数据库的简称，这类数据库不仅具有NoSQL对海量数据的存储管理能力，还保持了传统数据库支持ACID和SQL特性。

# 第6章 云数据库

下列Amazon的云数据库属于关系数据库的是：

- A.Amazon Redshift
- B.Amazon SimpleDB
- C.Amazon RDS2.00/2.00
- D.Amazon DynamoDB

正确答案：C你选对了

下列关于UMP系统的说法不正确的是：

- A.Agent服务器部署在运行MySQL进程的机器上，用来管理每台物理机上的MySQL实例
- B.UMP系统是低成本和高性能的MySQL云数据库方案
- C.Mnesia是UMP系统的一个组件，是一个分布式数据库管理系统，且不支持事务
- D.Controller服务器向UMP集群提供各种管理服务，实现集群成员管理、元数据存储等功能0.00/2.00

正确答案：C你错选为D

UMP依赖的开源组件包括:

- A.LVS0.75/3.00
- B.ZooKeeper0.75/3.00
- C.Mnesia0.75/3.00
- D.RabbitMQ0.75/3.00

正确答案: A、B、C、D你选对

在UMP系统中, Zookeeper主要发挥的作用包括:

- A.监控所有MySQL实例该题无法得分/3.00
- B.提供分布式锁, 选出一个集群的“总管”该题无法得分/3.00
- C.作为全局的配置服务器该题无法得分/3.00
- D.负责集群负载均衡该题无法得分/3.00

正确答案: A、B、C你错选为A、B、C、D

UMP系统设计了哪些机制来保证数据安全:

- A.SSL数据库连接0.75/3.00
- B.SQL拦截0.75/3.00
- C.数据访问IP白名单0.75/3.00
- D.记录用户操作日志0.75/3.00

正确答案: A、B、C、D你选对了

## 第7章 MapReduce

1 下列说法错误的是:

- A.MapReduce框架采用了Master/Slave架构, 包括一个Master和若干个Slave
- B.不同的Map任务之间不能互相通信
- C.Hadoop框架是用Java实现的, MapReduce应用程序则一定要用Java来写2.00/2.00
- D.Map函数将输入的元素转换成<key,value>形式的键值对

正确答案: C你选对了

2 在使用MapReduce程序WordCount进行词频统计时, 对于文本行“hello hadoop hello world”, 经过WordCount程序的Map函数处理后直接输出的中间结果, 应该是下面哪种形式:

- A.<"hello",2>、<"hadoop",1>和<"world",1>
- B.<"hello",1>、<"hello",1>、<"hadoop",1>和<"world",1>
- C.<"hello",1,1>、<"hadoop",1>和<"world",1>
- D.<"hello",<1,1>>、<"hadoop",1>和<"world",1>0.00/2.00

正确答案：B你错选为D

3对于文本行“hello hadoop hello world”，经过WordCount的Reduce函数处理后的结果是：

- A.<"hello",2><"hadoop",1><"world",1>2.00/2.00
- B.<"hello",1><"hello",1><"hadoop",1><"world",1>
- C.<"hello",<1,1>><"hadoop",1><"world",1>
- D.<"hello",1,1><"hadoop",1><"world",1>

正确答案：A你选对了

4下列关于传统并行计算框架（比如MPI）和MapReduce并行计算框架比较正确的是：

- A.前者所需硬件价格贵，可扩展性差，后者硬件便宜，扩展性好0.75/3.00
- B.前者是共享式(共享内存/共享存储)，容错性差，后者是非共享式的，容错性好
- C.前者相比后者学习起来更难
- D.前者适用于实时、细粒度计算、计算密集型，后者适用于批处理、非实时、数据密集型0.75/3.00

正确答案：A、B、C、D你错选为A、D

5MapReduce1.0的体系结构主要由哪几个部分组成：

- A.TaskTracker0.75/3.00
- B.Client0.75/3.00
- C.Task0.75/3.00
- D.JobTracker0.75/3.00

正确答案：A、B、C、D你选对了

9.MapReduce中有这样一个原则:移动计算比移动数据更经济。试述什么是本地计算，并分析为何要采用本地计算。

答： MapReduce设计的一个理念就是“计算向数据靠拢”，而不是“数据向计算靠拢”，因为移动数据需要大量的网络传输开销，尤其是在大规模数据环境下，这种开销尤为惊人，所以，移动计算要比移动数据更加经济。

本地计算：在一个集群中，只要有可能，MapReduce框架就会将Map程序就近地在HDFS数据所在的节点运行，即将计算节点和存储节点放在一起运行，从而减少了节点间的数据移动开销。

11.是否所有的MapReduce程序都需要经过Map和Reduce这两个过程?如果不是，请举例说明。

答：不是。对于关系的选择运算，只需要Map过程就能实现，对于关系R 中的每个元组t,检测是否是满足条件的所需元组，如果满足条件，则输出键值对<,t>,也就是说，键和值都是t。这时的Reduce函数就只是一个恒等式，对输入不做任何变换就直接输出。

12.试分析为何采用Combiner可以减少数据传输量?是否所有的MapReduce程序都可以采用Combiner?为什么?

答：对于每个分区内的所有键值对，后台线程会根据key 对它们进行内存排序(Sort ),排序是MapReduce 的默认操作。排序结束后，还包含一个可选的合并(Combine )操作。如果用户事先没有定义Combiner 函数，就不用进行合并操作。如果用户事先定义了Combiner 函数，则这个时候会执行合并操作，从而减少需要溢写到磁盘的数据量。

所谓“合并”，是指将那些具有相同key 的<key,value>的value 加起来，比如，有两个键值对<\*xmu",1>和<\*xmu",1>,经过合并操作以后就可以得到一个键值对<\*xmu",2>,减少了键值对的数量。不过，并非所有场合都可以使用Combiner,因为，Combiner的输出是Reduce任务的输入，Combiner绝不能改变Reduce任务最终的计算结果，一般而言，累加、最大值等场景可以使用合并操作。

## 第8章 Hadoop再探讨

习题：

下列说法正确的是 (C)

- A. HDFS HA可用性不好
- B. 第二名称节点是热备份
- C. 第二名称节点无法解决单点故障问题
- D.HDFS HA提供高可用性，可以实现可扩展性、系统性能和隔离性

HDFS Federation设计不能解决“单名称节点”存在的哪个问题 (B)

- A.性能更高效
- B.单点故障问题
- C.良好的隔离性
- D.HDFS集群扩展性

下列哪些是Hadoop1.0存在的问题 (ABCD)

- A.表达能力有限
- B.抽象层次低
- C.开发者自己管理作业之间的依赖关系
- D.执行迭代操作效率低

对新一代资源管理调度框架YARN的理解正确的是 (ABC)

- A. YARN的体系结构包含三个组件：ResourceManager，NodeManager，ApplicationMaster
- B. MapReduce2.0是运行在YARN之上的计算框架，由YARN来为MapReduce提供资源管理调度服务
- C. YARN可以实现“一个集群多个框架”，即在一个集群上部署一个统一的资源调度管理框架
- D. YARN既是资源管理调度框架，也是一个计算框架

HDFS HA (High Availability) 是为了解决单点故障问题。 (A)

- A. 对
- B. 错

在HDFS Federation (HDFS联邦) 中，设计了多个相互独立的名称节点，使得HDFS的命名服务能够水平扩展。 (A)

A. 对

B. 错

相对于Hadoop1.0而言，Hadoop2.0主要增加了HDFS HA和HDFS Federation（联邦）等特性。（A）

A. 对

B. 错

## 第9章 数据仓库Hive

下列有关Hive和Impala的对比错误的是：

得分/总分

- A.Hive适合于长时间的批处理查询分析，而Impala适合于实时交互式SQL查询
- B.Hive与Impala中对SQL的解释处理比较相似，都是通过词法分析生成执行计划
- C.Hive在内存不足以存储所有数据时，会使用外存，而Impala也是如此2.00/2.00
- D.Hive与Impala使用相同的元数据

正确答案：C你选对了

下列关于Hive基本操作命令的解释错误的是：

- A.create table if not exists usr(id bigint,name string,age int);//如果usr表不存在，创建表usr，含三个属性id,name,age
- B.insert overwrite table student select \* from user where age>10; //向表usr1中插入来自usr表的age大于10的数据并覆盖student表中原有数据
- C.load data local inpath '/usr/local/data' overwrite into table usr; //把目录'/usr/local/data'下的数据文件中的数据以追加的方式装载进usr表2.00/2.00
- D.create database userdb;//创建数据库userdb

正确答案：C你选对了

下列说法正确的是：

- A.Hive本身不存储和处理数据，依赖HDFS存储数据，依赖MapReduce处理数据1.00/3.00
- B.Impala和Hive、HDFS、HBase等工具可以统一部署在一个Hadoop平台上1.00/3.00
- C.数据仓库Hive不需要借助于HDFS就可以完成数据的存储
- D.HiveQL语法与传统的SQL语法很相似1.00/3.00

正确答案：A、B、D你选对了

Impala主要由哪几个部分组成：

- A.State Store1.00/3.00
- B.Hive
- C.CLI1.00/3.00
- D.Impalad1.00/3.00

正确答案：A、C、D你选对了

以下属于Hive的基本数据类型是：

- A.STRING0.75/3.00
- B.FLOAT0.75/3.00
- C.TINYINT0.75/3.00
- D.BINARY0.75/3.00

正确答案：A、B、C、D你选对了

## 2. 简述hive与传统数据库的区别

|      | Hive   | 传统数据库     |
|------|--------|-----------|
| 数据插入 | 支持批量导入 | 支持单条和批量导入 |
| 数据更新 | 不支持    | 支持        |
| 索引   | 支持     | 支持        |
| 分区   | 支持     | 支持        |
| 执行延迟 | 高      | 低         |
| 扩展性  | 好      | 有限        |

### 6. 简述hive HA原理

将若干个hive实例纳入一个资源池，然后对外提供一个唯一的接口，进行proxy relay

对于程序开发人员，就把它认为是一台超强“hive”，每次它接收到一个hive查询连接后，都会轮询资源池里可用的hive资源

## 第10章 Spark

RDD操作分为转换（Transformation）和动作（Action）两种类型，下列属于动作（Action）类型的操作的是（A）

- A. count
- B. map
- C. groupBy
- D. filter

下列说法错误的是（B）

- A. Spark支持三种类型的部署方式：Standalone，Spark on Mesos，Spark on YARN
- B. RDD提供的转换接口既适用filter等粗粒度的转换，也适合某一数据项的细粒度转换
- C. RDD采用惰性调用，遇到“转换(Transformation)”类型的操作时，只会记录RDD生成的轨迹，只有遇到“动作(Action)”类型的操作时才会触发真正的计算

D.在选择Spark Streaming和Storm时，对实时性要求高（比如要求毫秒级响应）的企业更倾向于选择流计算框架Storm

下列大数据类型与其对应的软件框架不适应的是（D）

- A. 基于历史数据的交互式查询：Impala
- B. 基于实时数据流的数据处理：Storm
- C. 复杂的批量数据处理：MapReduce
- D. 图结构数据的计算：Hive

Apache软件基金会最重要的三大分布式计算系统开源项目包括（ABC）

- A. Hadoop
- B. Storm
- C. Spark
- D. MapReduce

Spark的主要特点包括（ABCD）

- A. 运行速度快
- B. 运行模式多样
- C. 容易使用
- D. 通用性好

下列关于Scala的说法正确的是（ABCD）

- A. Scala是Spark的主要编程语言，但Spark还支持Java、Python、R作为编程语言。
- B. Scala具备强大的并发性，支持函数式编程。
- C. Scala是一种多范式编程语言。
- D. Scala运行于Java平台，兼容现有的Java程序。

Spark的运行架构包括（ABCD）

- A. 运行作业任务的工作节点 Worker Node
- B. 每个工作节点上负责具体任务的执行进程 Executor
- C. 集群资源管理器 Cluster Manager
- D. 每个应用的任务控制节点 Driver

RDD，中文全称是（弹性分布式数据集），是分布式内存的一个抽象概念，提供了一种高度受限的共享内存模型。

## 第11章 流计算

流计算秉承一个基本理念，即数据的价值随着时间的流逝而\_\_\_，如用户点击流：

- A.不确定
- B.升高
- C.降低2.00/2.00



- D.不变

正确答案：C你选对了

Hadoop运行的是MapReduce任务，类似地，Storm运行的任务叫做\_\_\_\_

- A.Tuple
- B.Bolt
- C.Spout
- D.Topology2.00/2.00

正确答案：D你选对了

对于一个流计算系统来说，它应达到如下哪些需求：

- A.分布式0.75/3.00
- B.高性能0.75/3.00
- C.海量式0.75/3.00
- D.实时性0.75/3.00

正确答案：A、B、C、D你选对了

数据采集系统的基本架构包括哪些部分：

- A.Agent1.00/3.00
- B.Controller
- C.Collector1.00/3.00
- D.Store1.00/3.00

正确答案：A、C、D你选对了

以下哪些是开源的流计算框架：

- A.Twitter Storm该题无法得分/3.00
- B.IBM InfoSphere Streams该题无法得分/3.00
- C.Facebook Puma
- D.Yahoo! S4

正确答案：A、D你错选为A、B

下面哪几个属于Storm中的Stream Groupings的分组方式：

- A.广播发送0.75/3.00
- B.按照字段分组0.75/3.00
- C.随机分组0.75/3.00
- D.全局分组0.75/3.00

正确答案：A、B、C、D你选对了

## 第12章 Flink

以下哪个不是Flink的优势：

- A.同时支持流处理和批处理
- B.同时支持高吞吐、低延迟、高性能
- C.不支持增量迭代2.00/2.00
- D.支持有状态计算

正确答案：C你选对了

在Flink中哪个是基于批处理的图计算库：

- A.CEP
- B.SQL&Table库
- C.FlinkML0.00/2.00
- D.Gelly

正确答案：D你错选为C

下面关于Flink的说法正确的是：

- A.Flink起源于Stratosphere 项目，该项目是在2010年到2014年间由柏林工业大学、柏林洪堡大学和哈索普拉特纳研究所联合开展的1.00/3.00
- B.Flink可以同时支持实时计算和批量计算1.00/3.00
- C.Flink不是Apache软件基金会的项目
- D.Flink是Apache软件基金会的5个最大的大数据项目之一1.00/3.00

正确答案：A、B、D你选对了

Flink的主要特性包括：

- A.批流一体化0.75/3.00
- B.事件时间支持0.75/3.00
- C.精密的状态管理0.75/3.00
- D.精确一次的状态一致性保障0.75/3.00

正确答案：A、B、C、D你选对了

下面论述正确的是：

- A.Flink实现了Google Dataflow流计算模型，是一种兼具高吞吐、低延迟和高性能的实时流计算框架，并且同时支持批处理和流处理0.75/3.00
- B.Spark Streaming通过采用微批处理方法实现了高吞吐和容错性，但是牺牲了低延迟和实时处理能力0.75/3.00
- C.流处理架构需要具备低延迟、高吞吐和高性能的特性，而目前从市场上已有的产品来看，只有Flink可以满足要求
- D.Storm虽然可以做到低延迟，但是无法实现高吞吐，也不能在故障发生时准确地处理计算状态0.75/3.00

正确答案：A、B、C、D你错选为A、B、D

Flink常见的应用场景包括：

- A.数据流水线应用该题无法得分/3.00
- B.地图应用该题无法得分/3.00
- C.数据分析应用该题无法得分/3.00
- D.事件驱动型应用该题无法得分/3.00

正确答案：A、C、D你错选为A、B、C、D

Flink核心组件栈分为哪三层：

- A.API&Libraries层1.00/3.00
- B.Core层
- C.Runtime核心层1.00/3.00
- D.物理部署层1.00/3.00

正确答案：A、C、D你选对了

Flink有哪几种部署模式：

- A.YARN集群模式
- B.Local模式
- C.运行在GCE（谷歌云服务）和EC2（亚马逊云服务）上
- D.Standalone集群模式

正确答案：A、B、C、D你没选择任何选项

Flink系统主要由两个组件组成，分别为：

- A.TaskScheduler
- B.JobScheduler
- C.JobManager1.50/3.00
- D.TaskManager1.50/3.00

正确答案：C、D你选对了

在编程模型方面，Flink 提供了不同级别的抽象，以开发流或批处理作业，主要包括哪几个级别的抽象：

- A.SQL
- B.DataStream API（有界或无界流数据）以及 DataSet API（有界数据集）
- C.状态化的数据流接口
- D.Table API

正确答案：A、B、C、D你没选择任何选项

## 第13章 图计算

Pregel是一种基于\_\_模型实现的并行图处理系统：

- A.SBP
- B.TSP

- C.STP
- D.BSP2.00/2.00

正确答案：D你选对了

谷歌在后Hadoop时代的新“三驾马车”不包括：

- A.Pregel
- B.Hama
- C.Dremel
- D.Caffeine0.00/2.00

正确答案：B你错选为D

下列哪些是以图顶点为中心的，基于消息传递批处理的并行图计算框架：

- A.Giraph1.00/3.00
- B.Hama1.00/3.00
- C.Neo4j
- D.Pregel1.00/3.00

正确答案：A、B、D你选对了

以下关于Pregel图计算框架说法正确的是：

- A.Pregel采用检查点机制来实现容错0.75/3.00
- B.对于全局拓扑改变，Pregel采用了惰性协调机制0.75/3.00
- C.Aggregator提供了一种全局通信、监控和数据查看的机制0.75/3.00
- D.通常只对满足交换律和结合律的操作才会开启Combiner功能0.75/3.00

正确答案：A、B、C、D你选对了

Hama是Google Pregel的开源实现，是在HDFS上实现的BSP计算框架，弥补Hadoop在计算能力上的不足

对

填空Pregel的计算过程是由一系列被称为 的迭代组成的。

超步

Pregel图计算框架的顶点通讯是通过 来实现的。

消息传递机制